

Reporte Sistema RAG

Para este proyecto usé un corpus de 5 documentos sobre las Normas Globales de Auditoría Interna, enfocado en cinco temas: confidencialidad de la información, independencia del área de auditoría, evaluación de riesgos del trabajo, evaluación de hallazgos y comunicación final de resultados.

En total los documentos suman 6,320 palabras para asegurar que el motor de búsqueda vectorial tuviera trabajo que hacer, en total se trabajó con un total de 32 fragmentos indexados y se usó gemini-embedding-001 a través del SDK oficial de Google AI, tanto para los fragmentos como para las preguntas del usuario.

Implementé la partición en `app/chunk.py` con una ventana de 250 palabras porque es un tamaño balanceado; no es tan corto como para perder la idea principal de un párrafo, ni tan largo como para saturar la ventana de contexto del LLM y un overlap de 50 palabras así si un dato importante queda justo en el corte entre un fragmento y el siguiente, esas 50 palabras repetidas aseguran que la idea mantenga su coherencia en al menos uno de los chunks.

Para evitar que el modelo invente cosas, la abstención se maneja con la instrucción explícita en el prompt de `app/generate` donde se le ordena a Gemini responder únicamente con el contexto recuperado y responder "no tengo evidencia suficiente" si la respuesta no viene ahí, de igual manera en la bandera de la API si la búsqueda no trajo citas válidas, el endpoint marca "abstained": true, con esto, Streamlit lo detecta y muestra una advertencia en lugar de una respuesta normal.

Cada tecnología hace una tarea muy específica, Google AI transforma el texto de los chunks y las preguntas del usuario en vectores numéricos de alta dimensión. ChromaDB es nuestra base de datos vectorial persistente en disco, no inventa embeddings por su cuenta; solo almacena los vectores que le dimos de Google junto con el texto y sus metadatos, cuando entra una pregunta, hace la búsqueda geométrica (k-NN) y nos regresa los fragmentos más cercanos con su distancia/score y por último Google AI (Gemini) una vez que Chroma nos da los top-k fragmentos más parecidos, entra Gemini donde su único trabajo es leer esos fragmentos, redactar la respuesta final en español y colocar las citas numeradas apuntando a la fuente.